双臂抓取方案选择

该项目的目标是实现单/双臂的物体识别与自主抓取，大致包含：

- 基于深度相机视觉的抓取位姿生成（HGGD）
- 抓取动作顺序执行
- 特定物品识别与抓取位姿筛选（YOLO）
- 软体衣物的双臂抓取
- 刚体物体的双臂抓取

目前实现了单臂的抓取位姿生成与部分的抓取动作顺序执行，执行正在debug，包括修正点云与真实物体间的误差。

1. **特定物品识别与抓取位姿筛选**
   我考虑利用`YOLO`等视觉模型做特定物品的识别，识别之后分割出物体的点云，再结合HGGD计算的期望位姿进行筛选，筛选基于HGGD生成的置信度与中心位置。

2. **软体衣物的双臂抓取**
   针对软体衣物的双臂抓取，考虑其柔性和可变形特性，可以直接利用类似于`DINOv2`的视觉模型进行特征提取，直接生成抓取点，而由于软体物体的抓取对动作的精确性要求较低，对双臂之间做简单避障即可。

3. **刚体物体的双臂抓取**
   由于是针对刚体物体的双臂抓取，需要更高的运动控制精度与更复杂的控制策略，考虑采用基于大模型+传统运控的控制方法，如`OpenVLA-OFT`，利用其强大的动作协调能力和预训练优势，生成高质量的双臂动作序列。

   但是`OpenVLA-OFT`的模型复杂度较高，推理速度较慢，需要高性能GPU支持，因此在实际部署时需要权衡性能与效果，可能需要对模型进行剪枝或量化以适应实时控制的需求。

   所以初步考虑是通过轻量级的`VLA`模型生成一个支持双臂抓取的轨迹，再通过`MPC`的方式对轨迹进行跟踪与优化，并且考虑到机械臂没有自带力反馈，因此更现实的方案是通过一臂硬抓取，另一臂软接触辅助的方式来实现双臂抓取，避免机械臂之间的碰撞问题。

OpenVLA-OFT

- 优势：

1. **大模型预训练**：OpenVLA的基座模型是在包含百万级真实机器人交互的海量数据集（如Open X-Embodiment）上训练出来的【23 † L21-L23】。

2. **动作协调性**：OpenVLA-OFT本身就是基于双臂操作开发，在微调时，其动作生成机制使用并行解码，一次生成未来25步的双臂动作序列。这种设计天然保证了双臂动作在时序和空间上的高度协同。把双臂动作从“Token 概率”变成了“连续流向量”。这解决了双臂“打架”问题。
3. **训练微调**：OpenVLA-OFT支持轻量化微调（如LoRA或低秩适配），使得在特定任务上进行快速适配成为可能。

- 缺陷：

1. **模型复杂度**：OpenVLA-OFT的模型参数量较大，推理速度相对较慢，因此本地需要高性能GPU（如A100或4090 24G）才能实现实时控制。

- 架构：

1. `SigLIP + DINOv2` 视觉骨干
    - 输入：单帧多路相机图像（第三人称 + 手腕相机）。
    - 输出：每个图像的 patch embedding（例如 256 个向量）。
    - 作用：提取视觉特征，输出高维向量表示。
2. `MLP` 投影器
    - 输入：**视觉骨干的特征** + **机器人本体感知状态**（关节角度、末端位姿等）。
    - 输出：投影到语言嵌入空间的 token。
    - 作用：把视觉和本体感知信息转化成“语言模型能理解的 token”，与语言指令处于同一空间。
3. 语言指令 (Llama-2 7B)
    - 输入：**语言指令 token**（例如“把茄子放进锅里”）+ **视觉骨干的特征** + **机器人本体感知状态**，指令、视觉、本体 token 拼接在一起，形成一个统一的序列。
    - 作用：作为核心序列建模器，理解任务语境并生成动作。
4. 解码器 / 输出层
    - 原始 OpenVLA：Llama-2 解码器直接输出 7 个离散动作 token（位置 3 + 姿态 3 + 夹爪 1）。
    - OFT 改进：替换为 4 层 MLP，输出连续动作向量。
    - OFT+：支持动作分块（一次输出 K 步），并行解码，提升速度和稳定性。
5. 动作序列
    - 输出：例如 25 Hz 的连续动作流，每个动作是 7 维向量（Δ位置、Δ姿态、夹爪控制）。

- 作用：直接驱动机器人执行任务。

SigLIP + DINOv2 视觉骨干提取图像特征输出向量，MLP把视觉骨干网络的结果与本体感知变成token，再将这个视觉与本体感知的token加上语言指令token送入7b模型生成7维25步动作

Octo GitHub - octo-models/octo

采用基于 Transformer 的扩散策略（Diffusion Policy）

视觉模型 DINOv2 + 模仿学习 LeRobot (ACT)

纯粹的模仿学习，不基于大模型，而是采用具有极强空间感知能力的预训练模型，泛化能力差

视觉模型 DINOv2 + planning